3I009 Licence d'informatique

Cours 3 : Traitement et optimisation de requêtes

Evaluation et optimisation - 1

```
Avec count:

SELECT DISTINCT Ename, Title
FROM Emp, Project, Works
WHERE Budget > 250
AND Emp. Eno=Works. Eno
AND Project. Pno-Works. Pno
AND Project. Pno IN
(SELECT Pno
FROM Works
GROUP BY Pno
HAVING COUNT(*) > 2)

Sans count:

SELECT DISTINCT El. Ename, El. Title
FROM Emp El, Project, Works W1, Emp E2, Works W2
WHERE Budget > 250
AND El. Eno=W1. Eno AND E2. Eno = W2. Eno
AND Project. Pno=W1. Pno AND W2. Pno = W1. Pno
AND El. Eno <> E2. Eno

Evaluation ct optimisation - 3
```

```
EMP(ENO, ENAME, TITLE)
PROJECT(PNO, PNAME, BUDGET)
WORKS(ENO, PNO, RESP, DUR)

Problème

Soit la requête
pour chaque projet de budget > 250 qui emploie plus de 2
employés, donner le nom et le titre des employés

Comment l'exprimer en SQL ?

• Avec count : traduire en algèbre ?
```

• Sans count : plus complexe

Evaluation et optimisation - 2 2

Un plan d'exécution possible

```
SELECT DISTINCT E1.Ename, E1.Title
FROM Emp E1, Project, Works W1, Emp E2, Works W2
WHERE Budget > 250
AND E1.Eno=W1.Eno AND E2.Eno = W2.Eno
AND Project.Pno=W1.Pno AND W2.Pno = W1.Pno
AND E1.Eno <> E2.Eno
```

 $T_1 \leftarrow Lire \text{ la table Project et } s\'electionner \\ \text{les tuples de Budget} > 250$

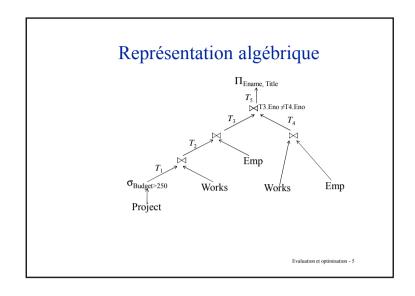
 $T_2 \leftarrow Joindre T_1$ avec la relation Works

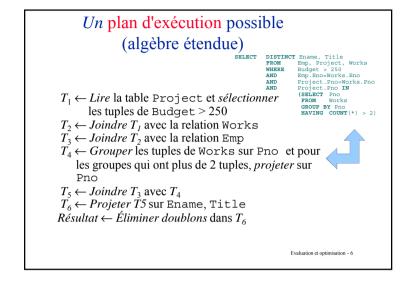
 $T_3^2 \leftarrow Joindre \ T_2^1$ avec la relation Emp

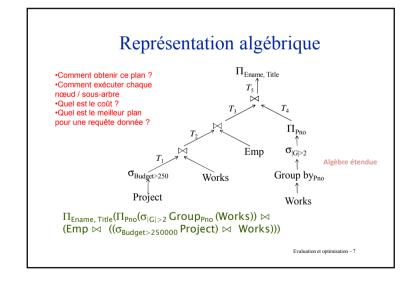
 $T_4 \leftarrow Joindre \, \mathbb{V}$ avec la relation Emp

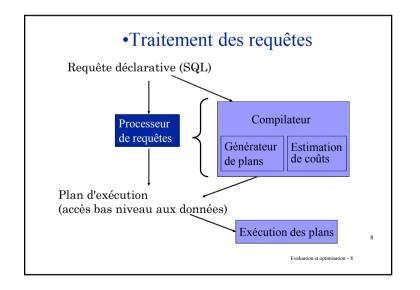
 $T_5 \leftarrow Joindre\ T_3$ avec T_4 en vérifiant T3. Eno \neq T4. Eno $T_6 \leftarrow Projeter\ T5$ sur Ename, Title

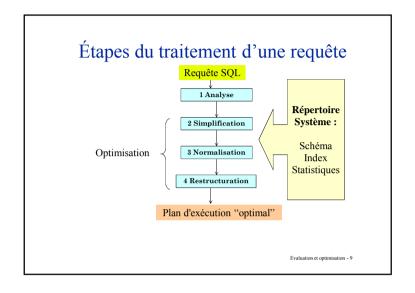
 $T_6 \leftarrow Projeter\ T3$ sur Ename, Title Résultat \leftarrow Éliminer doublons dans T_6











• Simplification • Pourquoi simplifier?

- - plus une requête est simple, plus son exécution peut être efficace
- Comment? en appliquant des transformations
 - élimination de la redondance
 - · règles d'idempotence

 $p_1 \land \neg (p_1) \equiv \text{faux}$ $p_1 \wedge (p_1 \vee p_2) \equiv p_1$ $p_1 \vee \text{faux} \equiv p_1$

- application de la transitivité (att1=att2 ,att2=att3)
- Éliminer des opérations redondantes :
 - ex. : pas besoin de distinct après une projection sur une clé
- utilisation des règles d'intégrité
 - CI: att1 <100 Q: ... where att1 > 1000...

élagage

Evaluation et optimisation - 11

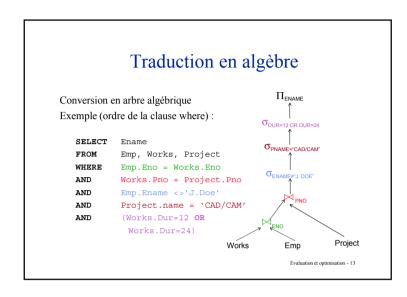
•Normalisation de requête

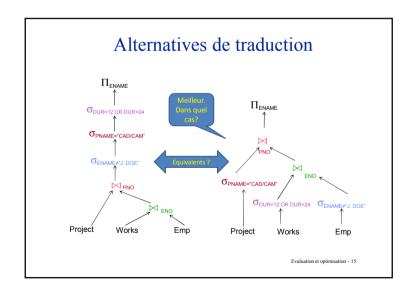
- Analyse lexicale et syntaxique
 - vérification de la validité de la requête
 - vérification des attributs et relations
 - vérification du typage de la qualification
- Mise de la requête en forme normale
 - forme normale conjonctive $(p_{11} \lor p_{12} \lor \dots \lor p_{1n}) \land \dots \land (p_{m1} \lor p_{m2} \lor \dots \lor p_{mn})$
 - forme normale disjonctive $(p_{11} \land p_{12} \land \dots \land p_{1n}) \lor \dots \lor (p_{m1} \land p_{m2} \land \dots \land p_{mn})$
 - OR devient union
 - AND devient jointure ou sélection

Evaluation et optimisation - 10 10

Exemple de simplification

```
SELECT
              Title
              Emp
FROM
WHERE
              Ename = 'J. Doe'
OR
              (NOT (Title = 'Programmer')
              (Title = 'Programmer'
AND
              Title = 'Elect. Eng.')
OR
              NOT(Title = 'Elect. Eng.'))
AND
                     P1 v (¬P2 ∧(P2 v P3) ∧ ¬P3)
SELECT
              Title
FROM
              Emp
WHERE
              Ename = 'J. Doe'
                                     Evaluation et optimisation - 12 12
```





Alternatives de traduction

SELECT Ename

FROM Emp e, Works w
WHERE e.Eno = w.Eno
AND w.Dur > 37

Stratégie 1:

 $\Pi_{\text{ENAME}}(\sigma_{\text{DUR}>37\land \text{EMP.ENO}=\text{WORKS.ENO}}(\text{Emp}\times\text{Works}))$

Stratégie 2:

 $\Pi_{ENAME}(Emp \bowtie_{ENO} (\sigma_{DUR>37}(Works)))$

•La stratégie 2 semble "meilleure" car elle évite un produit cartésien et sélectionne un sous-ensemble de Works avant la jointure

•Problème : Comment mesurer la qualité d'une stratégie ?

Evaluation et optimisation - 14

Optimisation de requête

Objectif: trouver le plan d'exécution le moins « coûteux »

Fonction de coût : donne une *estimation* du coût total réel d'un plan d'exécution coût total = coût I/O (entrées/sorties) + coût CPU

- a coût(I/O) ~ 1000 · coût(CPU) : on peut négliger le coût CPU
- I/O se calcule en nombre de page (même coût de transférer une page vide ou pleine)

»Problème 1 : Définition d'une bonne fonction de coût

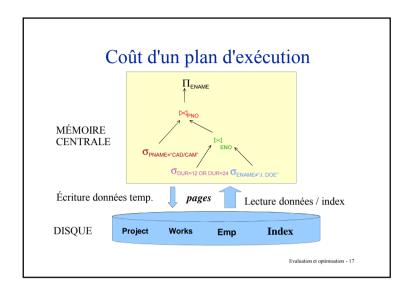
Solution: statistiques (à maintenir!) et fonctions d'estimations

Problème 2 : Taille de l'espace de recherche

Espace de recherche = ensemble des expressions algébriques équivalentes pour une même requête.

Peut-être très grand. Optimisation en temps borné si non-compilé

Solution : recherche non-exhaustive d'une bonne solution (pas forcément la meilleure) en limitant l'espace de recherche, ou utilisation d'heuristiques



Estimer le coût d'un plan

Deux hypothèses (fortes):

 Hypothèse d' uniformité: les différentes valeurs d'un attribut ont la même probabibilité.

Hypothèse plausible dans certains cas, pas dans d'autres (ex. âge)

2. Hypothèse d'*indépendance* des attributs : la probabilité d'un attribut ne dépend pas de la proba. d'un autre.

plausible : taille et couleur des cheveux peu plausible : taille et âge

Ces hypothèses sont trop forte mais

- On ne sait pas faire mieux sinon il faut stocker des histogrammes ...
 - Coûteux
 - · Compromis lecture / écriture
- L'erreur n'est pas fatale : au pire on choisit une solution un peu lente

Evaluation et optimisation - 19

Estimer le coût d'un plan

La fonction de coût donne une estimation des temps I/O et CPU

nombre instructions et accès disques (écriture/lecture en nb pages)

 Estimation du nombre d'accès disque pendant l'évaluation de chaque nœud de l'arbre algébrique

Dépend entre autres de la place mémoire disponible/taille des opérandes (principalement pour jointure) et de l'algo. utilisé pour mettre en œuvre l'opérateur (cf. semaine prochaine)

2. Estimation de la *taille du résultat* de chaque nœud par rapport à ses entrées :

sélectivité des opérations – « facteur de réduction »
influe sur la taille du résultat = opérande du prochain opérateur
basé sur les statistiques maintenues par le SGBD

EVALUATION - CONTINUE DE L'AUGUSTION - L'A

Tailles des relations intermédiaires Sélection: taille(R) = card(R) * largeur(R) $card(\sigma_F(R)) = SF_{\sigma}(F) * card(R)$ où SF_{σ} est une *estimation* de la **sélectivité du prédicat** , dont la forme générale est "taille des sélectionnés / taille des possibles (domaine)" $SF_{\sigma}(A = valeur) =$ $card(\prod_{A}(R))$ max(A) - valeurvaleur - min(A) $SF_{\sigma}(A > valeur) =$ $SF_{\sigma}(A < valeur) =$ max(A) - min(A)max(A) - min(A) $SF_{\sigma}(p(A_i) \wedge p(A_i))$ $= SF_{\sigma}(p(A_i)) \cdot SF_{\sigma}(p(A_i))$ $SF_{\sigma}(p(A_i) \vee p(A_i))$ $= SF_{\sigma}(p(A_i)) + SF_{\sigma}(p(A_i)) - (SF_{\sigma}(p(A_i)) \cdot SF_{\sigma}(p(A_i)))$ $= SF_{\sigma}(A=valeur) \cdot card(ens \ valeurs)$ $SF_{\sigma}(A \in \text{ens_valeurs})$

Tailles des relations intermédiaires

Projection

 $card(\Pi_A(R)) \le card(R)$ (égalité si A est *unique*)

Produit cartésien

 $card(R \times S) = card(R) \cdot card(S)$

Union

borne sup. : $card(R \cup S) = card(R) + card(S)$ borne inf. : $card(R \cup S) = max\{card(R), card(S)\}$

Différence

borne sup. : card(R-S) = card(R) /* $R \cap S = \emptyset$ borne inf. : 0 /* $R \subset S$

Evaluation et optimisation - 21

Règles de transformation

^aCommutativité des opérations binaires

 $R \times S \equiv S \times R$

 $R \bowtie S \equiv S \bowtie R$

 $R \cup S \equiv S \cup R$

«Associativité des opérations binaires

•($R \times S$) $\times T \equiv R \times (S \times T)$

• $(R \bowtie S) \bowtie T \equiv R \bowtie (S \bowtie T)$

«Idempotence des opérations unaires

 $\Pi_{A'}(\Pi_{A''}(R)) \equiv \Pi_{A'}(R)$

 $\bullet \sigma_{p_1(A_1)}(\sigma_{p_2(A_2)}(R)) \equiv \sigma_{p_1(A_1)} \wedge_{p_2(A_2)}(R)$

• où R[A] et $A' \subseteq A$, $A'' \subseteq A$ et $A' \subseteq A''$

Evaluation et optimisation - 23

Tailles des relations intermédiaires

Jointure:

⇒cas particulier: A est clé de R et B est clé étrangère dans S vers R : $card(R\bowtie_{A=B}S) = card(S)$

»plus généralement

 $card(R \bowtie S) = SF_J \bullet card(R) \bullet card(S)$

Comment l'obtenir ? Il faut des infos supplémentaire (SFj peut être stocké)

Evaluation et optimisation - 22

Règles de transformation

•Commutativité de la sélection et de la projection (si proj. des attr. sél.)

•Commutativité de la sélection avec les opérations binaires

 $\sigma_{p(A)}(R \times S) \equiv (\sigma_{p(A)}(R)) \times S$

 $\sigma_{p(A_i)}(R \bowtie_{(A_i,B_k)} S) \equiv (\sigma_{p(A_i)}(R)) \bowtie_{(A_i,B_k)} S$

 $\sigma_{p(A_i)}(R \cup T) \equiv \sigma_{p(A_i)}(R) \cup \sigma_{p(A_i)}(T)$

où A_i appartient à R et T

Commutativité de la projection avec les opérations binaires

 $\Pi_C(R \times S) \equiv \Pi_{A'}(R) \times \Pi_{B'}(S)$

 $\Pi_C(R \bowtie_{(A_i,B_k)} S) \equiv \Pi_{A'}(R) \bowtie_{(A_i,B_k)} \Pi_{B'}(S)$

 $\Pi_C(R \cup S) \equiv \Pi_C(R) \cup \Pi_C(S)$

où R[A] et S[B]; $C = A' \cup B'$ où $A' \subseteq A$, $B' \subseteq B$, $A_i \subseteq A'$, $B_k \subseteq B'$

Heuristiques

Observation: opérations plus ou moins coûteuses et plus ou moins sélectives

Idée : réordonner les opérations :

faire les opérateurs les moins coûteux (projection, sélection) et les plus sélectives en premier, de manière à réduire la taille des données d'entrée pour les opérateurs les plus coûteux (jointure). La place en mémoire est un facteur primordial pour l'efficacité d'une jointure (cf. dans 2 semaines)

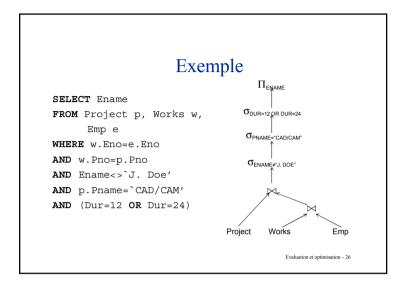
Méthode heuristique:

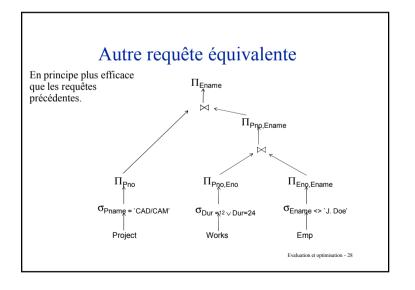
descendre les sélections, puis les projections au maximum grâce aux règles de transformation.

N'est pas toujours meilleur, car dépend de la présence d'index, de la nécessité d'écrire des relations temporaires...

Evaluation et optimisation - 25

Requête équivalente Tename A éviter! A éviter! A ppliquons l'heuristique décrite précédemment...





Conclusion

- Un SGBD doit transformer une requête déclarative en un programme impératif :
 - Plan d'exécution
 - Algèbre
- Calculer les tailles des résultats intermédiaire donne une idée du coût d'un plan mais..
 - Comment mettre en œuvre les opérateurs ?
 - Comment accéder aux données ?
 - Comment enchaîner les opérateurs ?
 - Comment trouver le meilleur plan en fonction de ce qui précède